

Intrusion Detection sul dataset UNSW-NB15

Classificazione Binaria e Multiclasse del Traffico di Rete

Simone Montagnini

Università di Bologna

Settembre 2026

- 1 Introduzione
- 2 Analisi Esplorativa dei Dati
- 3 Preprocessing
- 4 Selezione degli attributi
- 5 Classificazione
- 6 Conclusioni

Obiettivi del Progetto

Questo progetto affronta il rilevamento delle intrusioni nel traffico di rete attraverso due task di classificazione:

- **Classificazione binaria:** distinzione tra traffico normale e malevolo (`label`)
- **Classificazione multiclasse:** identificazione della minaccia specifica tra 9 possibili tipologie (`attack_cat`)

Sorgente

Competizione Kaggle: *Advanced AI for Cybersecurity — Intrusion Detection with UNSW-NB15*

- Dataset di traffico di rete realistico contenente attività sia normali che malevole
- **175.341** record di training, **36** feature iniziali (categoriche e numeriche)
- Due colonne target:
 - label: 0 = normale, 1 = attacco
 - attack_cat: Normal, Generic, Exploits, Fuzzers, DoS, Reconnaissance, Analysis, Backdoor, Shellcode, Worms

Distribuzione del Target

Binaria (label)

- Attacco: 68.1%
- Normale: 31.9%

Multiclasse (attack_cat)

- Normal: 56.000
- Generic: 40.000
- Exploits: 33.393
- Fuzzers: 18.184
- DoS: 12.264
- Reconnaissance: 10.491
- Analysis: 2.000
- Backdoor: 1.746
- Shellcode: 1.133
- **Worms: 130**

Sbilanciamento

Il target binario è relativamente bilanciato, ma `attack_cat` presenta forti sbilanciamenti: la classe Worms è **430 volte meno numerosa** rispetto a Normal; da qui la necessità di strategie di **class-weighting** nel modello multiclasse.

- **Righe duplicate:** 78.519 su 175.341 (**44,8%**)
 - Rimosse prima dello split, così da evitare data leakage tra train e test
- **Feature categoriche:**
 - proto (Alta cardinalità): 133 valori unici (tcp/udp $\approx$ 82% del traffico)
 - service: 13 valori, 54% mancanti/sconosciuti (-)
 - state: 9 valori

Feature Numeriche Asimmetriche

Diverse feature del traffico presentano distribuzioni right-skewed:

Feature	Asimmetria
trans_depth	167.3
response_body_len	76.3
sbytes	45.3
sloss	44.8
dloss	41.4
spkts	40.2

27 feature superano il limite (> 1.0) e subiranno una trasformazione logaritmica ($\log_{1p}$) in fase di preprocessing.

- ➊ **Rimozione duplicati:** rimosse 78.519 righe duplicate prima dello split
- ➋ **Split train/test:** 67/33, stratificato su label
- ➌ **Encoding:** OneHotEncoder su proto, service, state — 185 feature totali
- ➍ **Correzione asimmetria:** trasformazione $\log_{1p}$ su 27 feature (asimmetria > 1.0)

Scelta chiave

Le operazioni di preprocessing eseguono il **fit solamente sul training set** e vengono applicate sul test set grazie a `transform()` così da evitare data leakage.

- **Netta separazione:** Fare il fit degli encoder sull'intero dataset inietta conoscenza futura nella fase di addestramento
- **Gestione dati mai visti:** Categorie rare (e.g. all'interno dei 133 valori di proto) potrebbero apparire solamente nel test set
- **Tolleranza ai guasti:** `OneHotEncoder` è configurato con `handle_unknown='ignore'` per aggirare nuove categorie senza causare blocchi durante l'esecuzione

- **Feature selection supervisionata:** ogni feature viene valutata rispetto al target, mantenendo solamente le migliori k feature
- **Funzione di score:** ANOVA F-value (`f_classif`)
 - `mutual_info_classif` è stata esclusa a causa del costo computazionale eccessivo data la dimensione del dataset.
- **Selezione:** $k = 50$ su 185 feature, selezionate separatamente per `label` e `attack_cat`

Preservazione dell'Interpretabilità

SelectKBest mantiene gli attributi originali del traffico. In questo modo il modello rimane trasparente, permettendo di ricondurre direttamente le attività malevole a specifici segnali di rete.

- **Scaling preliminare:** feature standardizzate (StandardScaler), con fit della PCA esclusivamente sul training set
- **Varianza spiegata:** mantenere il 90% della varianza richiede **137 componenti** (118 per l'80%)
- **Riduzione limitata:** le componenti mantenute rappresentano ancora circa il 74% delle feature originali

Analisi delle Componenti e Contributo delle Feature

Piuttosto che essere dominate dalle numerose colonne proto codificate con one-hot encoding, le componenti principali mostrano un mix di tipologie di dati sottostanti. Per esempio, la PC2 è guidata quasi interamente da feature legate alle tempistiche e ai byte (sinpkt, dload, tcprtt)

Confronto sulla Selezione delle Feature

	SelectKBest	PCA
Dimensionalità	50 feature	137 componenti
Interpretabilità	Alta (dominio originale)	Bassa (combinazioni lineari)
Trasformazione	Supervisionata (target-aware)	Non supervisionata
Efficienza di training	Accettabile	Proibitiva

Scelta di Progettazione

PCA è stata esclusa dalla pipeline di classificazione: anche con un numero ridotto di componenti, l'overhead computazionale durante la GridSearchCV è risultato proibitivo. Pertanto, la classificazione procede solamente con SelectKBest.

Metodologia di Classificazione

- **Algoritmi:** Decision Tree (come baseline) e Random Forest
- **Tuning degli Iperparametri:** `max_depth` e `criterion` per Decision Tree, `n_estimators` e `max_depth` per Random Forest, `class_weight` None vs 'balanced' per entrambi
- **Gestione dello Sbilanciamento:** incluso `class_weight` (None vs 'balanced') per valutare la strategia migliore sui vettori di minaccia rari
- **Validazione:** 3-fold StratifiedKFold per garantire una rappresentazione proporzionale di tutte le classi durante il training

Metriche di Valutazione

L'Accuracy è fuorviante su dataset fortemente sbilanciati. I modelli sono valutati sulla base di **F1-Score** (classificazione binaria) e **Macro F1-Score** (classificazione multiclasse) per pesare correttamente le performance sulle classi minoritarie.

Risultati Classificazione Binaria

Performance Modello

Metrica	DT	RF
Accuracy	0.916	0.920
Precision	0.918	0.923
Recall	0.916	0.920
F1-Score	0.916	0.920

DT = Decision Tree, RF = Random Forest

- Random Forest raggiunge un eccellente F1-Score di **0.920**.
- Il modello è **molto affidabile** nella distinzione delle attività malevole dal traffico normale.





Figura: Matrice di Confusione Binaria

Risultati Classificazione Multiclasse

La sfida Multiclasse

- Il modello migliore ottiene un **Macro F1-Score** di **0.57**
- Le **classi più frequenti** (Normal, Generic) vengono predette con alta confidenza
- Le **classi rare** abbassano la media macro a causa della sovrapposizione delle feature e della scarsità di esempi per l'addestramento





Impatto del Bilanciamento

Grazie a `class_weight='balanced'`, il modello riesce a rilevare anche istanze di attacchi molto rari (come Worms), evitando quindi che vengano completamente ignorate.

Figura: Matrice di Confusione Multiclasse

Analisi Feature Importance

- **Task binario:** si basa prevalentemente sulle feature temporali del TCP handshake (`ackdat`, `synack`, `tcprtt`): gli handshake anomali rappresentano un forte indicatore di traffico malevolo
- **Task multiclasse:** si affida a feature volumetriche legate al trasferimento di byte (`sbytes`, `smean`, `dbytes`) per distinguere il *tipo* di attacco



- **Trade-off metodologici:** favorire l'interpretabilità (SelectKBest e modelli ad albero) si è rivelato altamente efficace per la detection binaria, ottenendo un F1-Score di 0.92 pur mantenendo regole decisionali trasparenti
- **Il limite del Multiclasse:** differenziare i singoli vettori di attacco rimane intrinsecamente difficile (Macro F1: 0.57). La matrice di confusione ha rivelato una forte sovrapposizione tra categorie correlate (e.g. DoS/Exploits, Backdoor/Analysis) e, in particolare, tra Fuzzers e traffico Normal
- **Dipendenza dalla Qualità dei Dati:** Il progetto ha mostrato come l'estremo sbilanciamento delle classi limiti pesantemente l'upper bound teorico delle performance di qualsiasi classificatore standard

Per superare i limiti attuali e portare il sistema verso un Network Intrusion Detection System (NIDS) realistico, iterazioni future potrebbero esplorare:

- **Resampling Avanzato:** nonostante SMOTE sia stato inizialmente valutato, è stato scartato a causa dell'estremo overhead computazionale. Lavori futuri dovranno indagare tecniche di campionamento altamente ottimizzate e scalabili
- **Architetture Alternative:** Valutare classificatori non basati su alberi per determinare se confini matematici differenti possano isolare meglio classi rare
- **Feature Engineering di Dominio:** derivare nuove feature di rete altamente specifiche, mirate a distinguere meglio la sovrapposizione delle firme degli attacchi minoritari rispetto alle anomalie più frequenti